

Estudo Comparativo Entre Arquiteturas de Deep Learning Para Detecção de Falsificações em Imagens.



Por Thales A. Paletti Pomari
Orientado por Prof. Dr. Tiago Carvalho

Sumário

- Introdução
 - Justificativa
 - Objetivos
 - Fundamentação Teórica
 - Metodologia
 - Experimentos e Resultados
 - Conclusões
 - Bibliografia
-

Introdução

- Volume de imagens circulando;
- Softwares de edição;
- *Splicing*.



Imagem 1: Exemplo de falsificação do tipo *splicing*.

Introdução

- Perigo de *Fake News*;
- Técnicas de reconhecimento de padrões;



Imagem 2: Exemplo de Fake News utilizando imagens.

Justificativa

Avaliar o desempenho de diferentes arquiteturas de CNN desenvolvidas para o contexto de reconhecimento de objetos, porém aplicadas ao problema de detecção de falsificações de imagens compostas.

Objetivo Geral

- Realizar um estudo comparativo entre as arquiteturas tradicionais de reconhecimento de padrões para o problema de classificação de imagens falsas.

Objetivos Específicos

- Analisar o desempenho do uso de propriedades de iluminação das imagens;
- Estudar e comparar as arquiteturas estado da arte;

Fundamentação Teórica

Propriedades de Iluminação

- Mapa de Iluminância;
 - grau de incidência da onda;
- Baseados em física e estatística;
- Característica de difícil replicação.




Imagem 3: Exemplo do grau de Incidência.

Exemplo dos Mapas de Iluminância



Imagem 4: Splicing RGB.



Imagem 5: Splicing GGE.




Imagem 6: Splicing IIC.

Redes Neurais

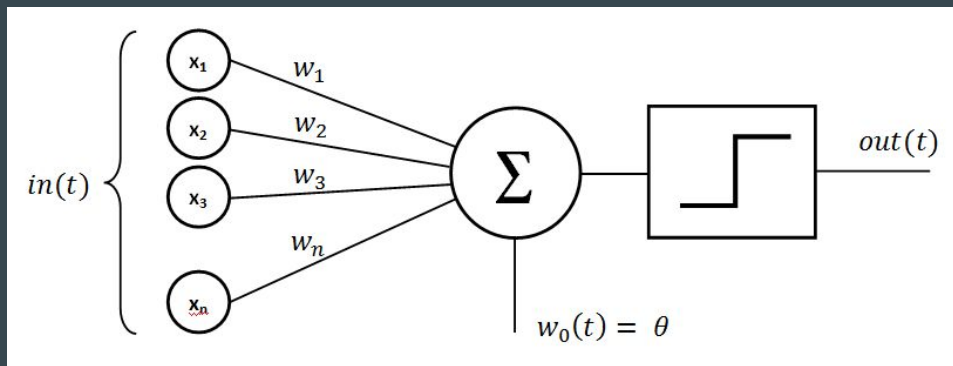


Imagem 7: Modelo de um neurônio..

- Conceito de 1940;
- Baseia-se nas sinapses;
- Composta por neurônios e camadas.




Imagem 8: Exemplo de uma rede.

Redes Neurais Profundas




Imagem 9: Diferença entre redes simples e profundas.

Redes Neurais Convolucionais

- Propostas para imagens;
- Adição da camada de convolução:
 - aplicação de filtros;
- Alto poder de reconhecimentos de padrões.



Imagem 10: Exemplo de convolução.¹³

Redes Neurais Convolucionais Profundas




Imagem 11: Exemplos de filtros de características.

Arquiteturas Utilizadas

VGG

- Visual Geometry Group;
- Conceito clássico.

ResNet

- Microsoft Research;
- Conceito de bloco residual.

Inception

- Google;
- Conceito do módulo Inception.

Classificador

- Sem o topo padrão;
- Treinamento supervisionado;
- Máquina de Vetores de Suporte (SVM).




Imagem 12: Exemplo gráfico do SVM.

Análise de Resultado

- **Matriz de confusão;**
- **Confiabilidade da rede;**
- **Acurácia.**

	Splicing	Verdadeira
Splicing	Classificação Correta	Classificação Incorreta
Verdadeira	Classificação Incorreta	Classificação Correta

Imagem 13: Matriz de confusão.

Metodologia

Metodologia

- Dividida em 4 Etapas:
 1. Extração dos Mapas;
 2. Pré-processamento das imagens;
 3. Extração das Características;
 4. Treinamento e Validação do Classificador.

1 - Extração dos Mapas

- Utiliza imagens em seu tamanho original;

2 - Pré-Processamento das Imagens

- Separação de canais RGB;
- Redimensionamento;
- Normalização do valor de cada pixel.

3 - Extração das Características

- Alimentação da rede;
- Aplicação do transfer learning;
- Vetor de características;

4 - Treinamento e Validação do Classificador

- Separação das Amostras em 5 partes;
- Realização do treino e teste;
- Geração dos gráficos de avaliação.

Experimentos e Resultados

Ambiente de Desenvolvimento e Ferramentas

- Ambiente de testes:
 - Intel(R) Xeon(R) E5-2620;
 - 100 GB RAM;
 - 1 GPU Titan X;
 - Python 3.5.
- Principais bibliotecas:
 - Keras 2.0.3;
 - Tensorflow 1.0.1;
 - ScikitLearn 0.19.1;
 - Matplotlib 3.0.3.

Bases de Dados

- DSO - 200 imagens;
- Columbia - 363 imagens;
- DSI - 50 imagens.



Imagem 14: DSO.



Imagem 15: Columbia.



Imagem 16: DSI.

Quantidade de Testes Realizados

Redes Neurais

1. ResNet50
2. VGG16
3. VGG19
4. InceptionV3
5. InceptionResNetV2

Variações por Base

<u>DSO</u>	<u>Columbia</u>	<u>DSO</u>
A. IIC	A. IIC	A. IIC
B. GGE	B. GGE	B. GGE
C. RGB	C. RGB	C. RGB

Resultados

- DSO:
 - VGG19 = 94%;
- DSI:
 - ResNet50 = 90%;
- Columbia:
 - ResNet50 = 82,3%.

IIC			
Rede	DSO	DSI	Columbia
ResNet50	91%	90%	82,3%
VGG16	91,5%	86%	77,9%
VGG19	94%	84%	78,5%
InceptionV3	87%	84%	63,1%
InceptionResNetV2	93%	86%	51,8%

Imagem 17: Tabela de resultados IIC.

Resultados

- DSO:
 - ResNet50 = 60,5%;
- DSI:
 - ResNet50 = 68%;
- Columbia:
 - ResNet50 = 81,5%.

GGE			
Rede	DSO	DSI	Columbia
ResNet50	60,5%	68%	81,5%
VGG16	59,5%	60%	77,7%
VGG19	59%	62%	81%
InceptionV3	53,5%	60%	73%
InceptionResNetV2	45,5%	44%	60%

Imagem 18: Tabela de resultados GGE.

Resultados

- DSO:
 - InceptionV3 = 63%;
- DSI:
 - VGG19 = 74%;
- Columbia:
 - ResNet50 = 84,6%.

RGB			
Rede	DSO	DSI	Columbia
ResNet50	58,5%	72%	84,6%
VGG16	58,5%	72%	82%
VGG19	53,5%	74%	82%
InceptionV3	63%	42%	63%
InceptionResNetV2	56%	56%	70%

Imagem 19: Tabela de resultados RGB.

Conclusões

CONCLUSÕES

- Relação entre acurácia e quantidade de amostras;
- Eficácia dos mapas de iluminância;
- Acurácia não é o único parâmetro de decisão;
- Desempenho da ResNet.

BIBLIOGRAFIA

1. Por ano, 125 bilhões de imagens são compartilhadas na rede. -
<https://oglobo.globo.com/economia/por-ano-125-bilhoes-de-imagens-sao-compartilhadas-na-rede-8301345>
2. É #FAKE imagem em que Manuela D'Ávila aparece com camiseta 'Jesus é travesti' -
<https://extra.globo.com/fato-ou-fake/e-fake-imagem-em-que-manuela-davila-aparece-com-camiseta-jesus-travesti-23119933.html>
3. Luminância vs. Iluminância -
<http://sensing.konicaminolta.com.br/2015/09/luminancia-vs-iluminancia/>
4. Redes Neurais -
HAYKIN, Simon. Redes neurais: princípios e prática . [S.l.]: Bookman Editora, 2007. 61 p.
5. O Que São Redes Neurais Artificiais Profundas ou Deep Learning? -
<http://deeplearningbook.com.br/o-que-sao-redes-neurais-artificiais-profundas/>
6. Máquina de Vetores de Suporte-
JAKKULA, Vikramaditya. Tutorial on support vector machine (svm). School of EECS, Washington State University, v. 37, 2006.

Obrigado a todos.

VGG

- Visual Geometry Group;
- Conceito padrão;




Imagem 10: Diagrama da VGG16.

ResNet

- Microsoft Research;
- Introdução do conceito residual;




Imagem 11: Bloco de convolução.

Inception

- Google;
- Módulo Inception;

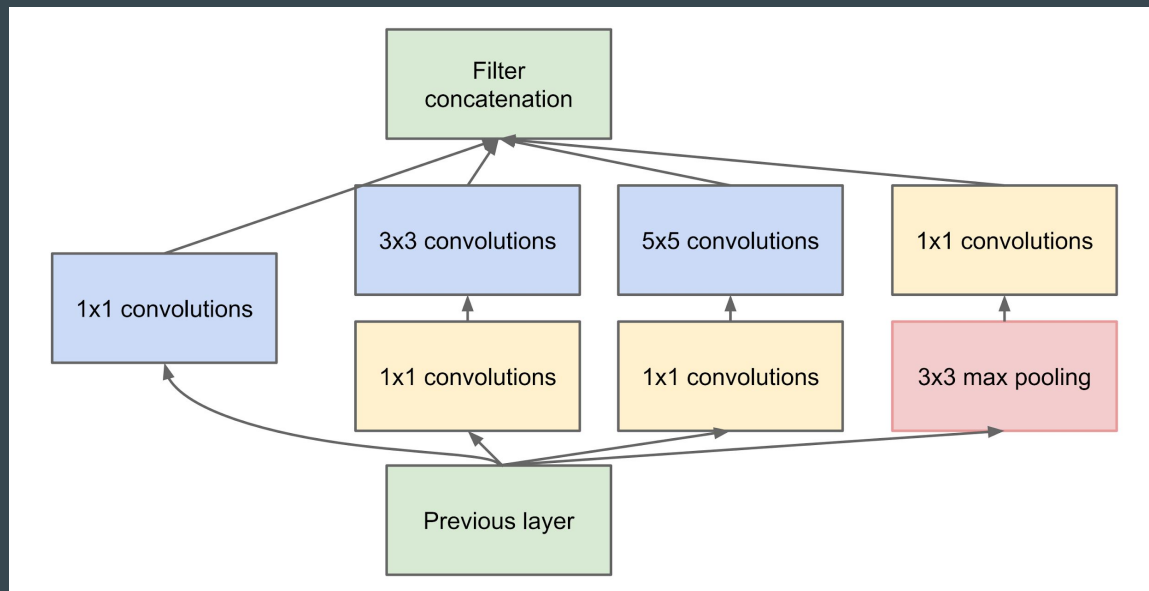


Imagem 12: Módulo Inception.